

Part1递归算法

2023年3月30日 15:56

Filter --> optimal recursive(递归) data processing algorithm

不确定性:

- 1) 不存在完美的数学模型
- 2) 系统的扰动不可控, 也很难建模
- 3) 测量的传感器存在着误差

递归的思想:

假设有k个测量的结果($Z_1 \cdots Z_k$), 那么我们估计真实的数据如下所示:
我们令根据k次测量结果得到的均值为 \hat{x}_k , 那么可以得到下面这样的公式:

$$\hat{x}_k = \frac{1}{K}(Z_1 + Z_2 + \cdots Z_K)$$
$$= \frac{1}{K}(Z_1 + Z_2 + \cdots Z_{K-1}) + \frac{1}{K}Z_K$$
$$= \frac{1}{K} \frac{K-1}{K-1} (Z_1 + Z_2 + \cdots Z_{K-1}) + \frac{1}{K}Z_K$$
$$= \frac{K-1}{K} \hat{x}_{k-1} + \frac{1}{K}Z_K$$
$$= \hat{x}_{k-1} - \frac{1}{K} \hat{x}_{k-1} + \frac{1}{K}Z_K = \hat{x}_{k-1} + \frac{1}{K}(Z_K - \hat{x}_{k-1})$$

When $k \rightarrow \infty, \frac{1}{K} \rightarrow 0$, then $\hat{x}_k \rightarrow \hat{x}_{k-1}$
说明随着测量的增加, 测量的结果也就不再重要了。
而当k值比较小的时候, Z_k 的影响就比较大了。
此时我们可以提炼一下系数。令 $K_k = \frac{1}{K}$ (大K指的是Kalman)

则 $\hat{x}_k = \hat{x}_{k-1} + K_k(Z_k - \hat{x}_{k-1})$
含义为

当前的估计值 = 上一次的估计值 + 系数 * (当前的测量值 - 上一次的估计值)

K_k 又成为kalman gain

Kalman filter 的一个重要的优势, 就在于它并不用追逐很早之前的估计值, 仅需要最近一次的估计值即可

下面介绍几个常用的参数
估计误差: $e_{est}(estimate)$
测量误差: $e_{MEA}(measurement)$

则此时kalman gain 可以写为:

$$K_k = \frac{e_{est\ k-1}}{e_{est\ k-1} + e_{MEA\ k}} \text{ (后续会解释)}$$

讨论,

当k时刻, $e_{est\ k-1} \gg e_{MEA\ k}$ 时, $K_k \rightarrow 1$, $\hat{x}_k = \hat{x}_{k-1} + K_k(Z_k - \hat{x}_{k-1}) \approx \hat{x}_k = \hat{x}_{k-1} + (Z_k - \hat{x}_{k-1}) = Z_k$, 则说明估计的误差大, 要更加信任测量值

当k时刻, $e_{est\ k-1} \ll e_{MEA\ k}$ 时, $K_k \rightarrow 0$, $\hat{x}_k = \hat{x}_{k-1} + K_k(Z_k - \hat{x}_{k-1}) \approx \hat{x}_{k-1}$, 则说明估计的误差比较小, 要更加信任估计值。

因此利用kalman filter去解决相关问题的最基本的方法为:

Step1: 计算kalman gain, $K_k = \frac{e_{est\ k-1}}{e_{est\ k-1} + e_{MEA\ k}}$

Step2: 计算 $\hat{x}_k = \hat{x}_{k-1} + K_k(Z_k - \hat{x}_{k-1})$

Step3: 更新估计误差 $e_{est\ k} = (1 - K_k)e_{est\ k-1}$(后续会解释)

例题:


假设一物体的长度为50mm

第一次测量 $\hat{x}_0 = 40mm; e_{est\ 0} = 5mm; Z_1 = 51mm; e_{MEA\ 0} = 3mm$;

则

k	Z_k	$e_{MEA\ k}$	\hat{x}_k	K_k	$e_{est\ k}$
0			40		5
1	51	3	46.875	0.625	1.875
2					
3					

$K = 1:$
 $K_k = \frac{5}{5+3} = 0.625$
 $\hat{x}_k = 40 + 0.625(51 - 40) = 46.875$
 $e_{est} = (1 - 0.625)5 = 1.875$




最终递归收敛到真实值附近

Part2 数学基础_数据融合_协方差矩阵_状态空间方程_观测器问题

2023年3月30日 17:02


Data Fusion:
例子开始：用两个不同的测量工具测量同一件物品， $Z_1 = 30, Z_2 = 32$ 。我们已知这两个的测量工具的测量标准差为： $\sigma_1 = 2, \sigma_2 = 4$ ，并且都符合正态分布。




那么如何去估计这件物品的真实值呢？

此时我们想要充分利用这两个数据，那么我们就需要把他们结合起来。我们设估计值为Z

$Z = Z_1 + K(Z_2 - Z_1)$
那么目前就是求解一个合适的K使得测量的误差最小---> $\text{var}(Z)$ 最小
 $\text{var}(Z) = \text{var}(Z_1 + K(Z_2 - Z_1)) = \text{var}((1-K)Z_1 + KZ_2)$
可以看到前后两项是相互独立的，因此
 $\text{var}(Z) = \text{var}((1-K)Z_1) + \text{var}(KZ_2) = (1-K)^2 \text{var}(Z_1) + K^2 \text{var}(Z_2) = ((1-K)\sigma_1)^2 + (K\sigma_2)^2$
然后我们就可以对k进行求导：
 $-2(1-K)\sigma_1^2 + 2K\sigma_2^2 = 0$ ，则可以求出：
 $K = \frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2}$



State space observation:



弹簧系数为k， 阻尼系数为B， 移动距离为x， 施加的力为F， 写出这个木块的状态方程

根据 $F=ma$ ，显然我们可以得到
 $m\ddot{x} + B\dot{x} + kx = F$
令 $F = u$ ，也就是系统的输入。
令 $x_1 = x, x_2 = \dot{x}$ ，
则 $\dot{x}_1 = x_2$ ，
 $\dot{x}_2 = \frac{1}{m}u - \frac{B}{m}\dot{x} - \frac{k}{m}x = \frac{1}{m}u - \frac{B}{m}x_2 - \frac{k}{m}x_1$ ，
假设此时还具有测量量：
 $Z_1 = x_1, Z_2 = x_2$
则：
 $\begin{bmatrix} \dot{x}_1 \\ \dot{x}_2 \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ -\frac{k}{m} & -\frac{B}{m} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + \begin{bmatrix} 0 \\ 1 \end{bmatrix} u$
 $\begin{bmatrix} Z_1 \\ Z_2 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$
因此状态空间方程可以写为：
 $\dot{x}(t) = Ax(t) + Bu(t)$
 $Z(t) = Hx(t)$

$\dot{x}(t)$ 表示的其实就是对于时间的变化

假如是离散的时刻，那么状态空间方程可以写为：
 $X_k = AX_{k-1} + BU_{k-1}$
 $Z_k = HX_k$ ，
其中下标表示为时间单位
当然并不是照抄上面的形式下来的，还是有具体的离散推导得到的

而由于我们提到过，kalman filter 解决的过程中存在着不确定性，那么
 $X_k = AX_{k-1} + BU_{k-1} + \omega_{k-1}$ ，
 ω_{k-1} 被称为过程噪音，
而同样，观测设备也同样存在着不确定性，那么
 $Z_k = HX_k + v_k$ ，
 v_k 被成为测量噪音。
那么在模型也不准确，测量也不准确的情况下，如何去估计得到一个精确的 \hat{X}_k ？
这就是kalman filter要解决的问题。

Covariance Matrix:
将方差和协方差在一个矩阵中表现出来，表明了变量间的一个联动的关系。
例子：

球员	身高	体重	年龄
瓦尔迪	179	74	33
奥巴梅扬	187	80	31
萨拉赫	175	71	28

计算：
 $\sigma_x^2 = \frac{1}{3}((179-180.3)^2 + (187-180.3)^2 + (175-180.3)^2) = 24.89$
 $\sigma_y^2 = 14$
 $\sigma_z^2 = 4.2$
协方差：
 $\sigma_{xy} = \frac{1}{3}((179-180.3)(74-76) + (187-180.3)(80-76) + (175-180.3)(71-76)) = 1.67 = \sigma_{yx}$

得到的协方差矩阵为：

$$P = \begin{bmatrix} \sigma_x^2 & \sigma_{xy} & \sigma_{xz} \\ \sigma_{yx} & \sigma_y^2 & \sigma_{yz} \\ \sigma_{zx} & \sigma_{zy} & \sigma_z^2 \end{bmatrix}$$

	G	H	I	J
	身高	体重	年龄	
身高	32.69	29.75	1.4	
体重	29.75	38.06	3.98	
年龄	1.4	3.978	19.4	

协方差值越大，说明相关程度越高，例如身高和体重，而年龄和身高、体重的值比较小，说明相关程度较小。

part3 Kalman gain 推导

2023年3月30日 19:25

上一节我们知道了状态方程的公式，

$$\begin{aligned}X_k &= AX_{k-1} + BU_{k-1} + \omega_{k-1}, \\Z_k &= HX_k + v_k,\end{aligned}$$

其中 ω_{k-1} 是过程噪声， v_k 是测量噪声，这一部分是不可测的，但是一般在自然界中可以将其假设成服从正态分布，也就是说

$$P(\omega) \sim (0, Q),$$

其中0是均值，而Q是协方差矩阵

$$Q = E(\omega\omega^T)$$

Q这个公式这一步是怎么来的呢

假设 X_k 是一个二维的向量，包含 $\begin{bmatrix}x_1 \\ x_2\end{bmatrix}$

那么自然而然 ω_{k-1} 也是一个二维的向量，即 $\begin{bmatrix}\omega_1 \\ \omega_2\end{bmatrix}$

$$\text{那么}\omega\omega^T = \begin{bmatrix}\omega_1 \\ \omega_2\end{bmatrix} \begin{bmatrix}\omega_1 & \omega_2\end{bmatrix} = \begin{bmatrix}\omega_1\omega_1 & \omega_1\omega_2 \\ \omega_2\omega_1 & \omega_2\omega_2\end{bmatrix},$$

$$\text{那么}E(\omega\omega^T) = \begin{bmatrix}E\omega_1\omega_1 & E\omega_1\omega_2 \\ E\omega_2\omega_1 & E\omega_2\omega_2\end{bmatrix},$$

$$\text{由于}\text{var}(x) = E(x^2) - E^2(x),$$

$$\text{由于}E(x)=0,$$

$$\text{因此}\text{var}(x) = E(x^2),$$

故 $Q = E(\omega\omega^T)$ 就是协方差矩阵了

同上，我们也认为 v_k 符合正态分布

$$P(v) \sim (0, R),$$

R就是测量噪声的协方差矩阵。

我们建模中不知道的便是 ω 和 v ，其余的矩阵是已知的，而我们通过

$X_k = AX_{k-1} + BU_{k-1}$ 这个公式得到的 \hat{X}_k 其实是不正确的，在这里在上面增加一个小小的负号，表明它是先验估计值。

$$\hat{X}_k^- = A\hat{X}_{k-1}^- + BU_{k-1}, \text{ (这里的}\hat{X}_{k-1}^- \text{也是估计值)}$$

由于我们是知道测试结果 Z_k ,

那么在不考虑测量噪音的情况下，可以大体得到一个估计的 \hat{X}_k ,

那么我们令这个估计的 \hat{X}_k 命名为 $\hat{X}_{k, mea}$,表示这是根据测试结果估计得到的 \hat{X}_k

那么，根据公式 $Z_k = HX_k$ ，可以得到

$$\hat{X}_{k, mea} = H^{-1}Z_k, \text{ (由于是可以观测的系统，因此H一定是可逆的)}$$

因此我们得到了两个不同的关于 X_k 的结果，一个是先验结果 \hat{X}_k^- (算出来的), 另一个是测出来的结果 $\hat{X}_{k, mea}$ (测出来的),

但是着两个其实都是不准确的，因为其没有考虑噪声的影响

我们真正要求的是 \hat{X}_k (表示后验), 包含了噪声的影响。

那么这里就要用到数据融合 (Data Fusion) 的概念了。

我们知道 \hat{X}_k^- , $\hat{X}_{k, mea}$

$$\text{那么}\hat{X}_k = \hat{X}_k^- + G(\hat{X}_{k, mea} - \hat{X}_k^-), \text{ (G是方阵)}$$

$$\hat{X}_{k, mea} = H^{-1}Z_k,$$

$$\text{那么}\hat{X}_k = \hat{X}_k^- + G(H^{-1}Z_k - \hat{X}_k^-),$$

$$\text{那么令}K_k = GH^{-1}, \text{便可以得到}\hat{X}_k = \hat{X}_k^- + K_k(Z_k - H\hat{X}_k^-),$$

$$\text{那么在此时}K_k \notin (0, 1), \text{而是}K_k \in (0, H^{-1}),$$

因此我们的目标就变得十分清晰了，就是求 K_k 使得考虑了噪声之后的估计值 \hat{X}_k 趋近于真实值 X_k ,

(那怎么取呢，很显然这里与误差息息相关)

那么此时引入误差:

$$e_k = X_k - \hat{X}_k, \text{同理}P(e_k) \sim (0, P), P \text{也是那个协方差矩阵}$$

而当在不同的维度上的方差越小，那么说明这个 e_k 越接近0, 因此估计值和真实值也就是最相近的。

所以，要选择合适的 K_k 使得 $\text{tr}(P)$ (矩阵对角线相加) 最小，那么优化问题就变成了下面这个公式。

$$P = E(e_k e_k^T) = E((X_k - \hat{X}_k)(X_k - \hat{X}_k)^T),$$

$$\text{将}\hat{X}_k = \hat{X}_k^- + K_k(Z_k - H\hat{X}_k^-) \text{代入,}$$

$$\text{可以得到}P = E((X_k - (\hat{X}_k^- + K_k(Z_k - H\hat{X}_k^-)))(X_k - (\hat{X}_k^- + K_k(Z_k - H\hat{X}_k^-)))^T),$$

那么此时将 $Z_k = HX_k + v_k$ 进行替换。

$$\text{那么}X_k - \hat{X}_k = X_k - \hat{X}_k^- - K_k(HX_k + v_k) + K_k H\hat{X}_k^- = X_k - \hat{X}_k^- - K_k H(X_k - \hat{X}_k^-) - K_k v_k = (I - K_k H)(X_k - \hat{X}_k^-) - K_k v_k,$$

由于 $e_k = X_k - \hat{X}_k$, 因此也可以命名 $X_k - \hat{X}_k^-$ 为 e_k 的先验, 记为 e_k^- ,

$$\text{因此此时的}P \text{可以改写为}P = E(e_k e_k^T) = E(((I - K_k H)e_k^- - K_k v_k) ((I - K_k H)e_k^- - K_k v_k)^T),$$

$$\text{根据矩阵运算} (AB)^T = B^T A^T, (A + B)^T = A^T + B^T,$$

$$\begin{aligned}\text{则}P &= E(((I - K_k H)e_k^- - K_k v_k)(e_k^{-T}(I - K_k H)^T - v_k^T K_k^T)) = E((I - K_k H)e_k^- e_k^{-T}(I - K_k H)^T - (I - K_k H)e_k^- v_k^T K_k^T \\ &\quad - K_k v_k e_k^{-T} - K_k v_k e_k^{-T} v_k^T K_k^T),\end{aligned}$$

求上述的期望，等价于求上述每一项的期望之和，

$$\text{即 } P = E \left((I - K_k H) e_k^- e_k^{-T} (I - K_k H)^T \right) + E \left(-(I - K_k H) e_k^- v_k^T K_k^T \right) + E \left(-K_k v_k e_k^{-T} (I - K_k H)^T \right) + E \left(K_k v_k v_k^T K_k^T \right),$$

由于 $(I - K_k H)$ 和 K_k^T 都是常数，因此中间的两项可以将常数提取出来，

$$P = E \left((I - K_k H) e_k^- e_k^{-T} (I - K_k H)^T \right) - (I - K_k H) E(e_k^- v_k^T) K_k^T - K_k E(v_k e_k^{-T}) (I - K_k H)^T + E(K_k v_k v_k^T K_k^T),$$

而因为 e_k^- 是算出来的， v_k 是测量误差，故这两个肯定是相互独立的，

故 $E(e_k^- v_k^T) = E(e_k^-) E(v_k^T) = 0$ ，同理第三项也是等于 0 (高斯分布)，

$$\text{故 } P = E \left((I - K_k H) e_k^- e_k^{-T} (I - K_k H)^T \right) + E(K_k v_k v_k^T K_k^T),$$

$$\text{故 } P = (I - K_k H) E(e_k^- e_k^{-T}) (I - K_k H)^T + K_k E(v_k v_k^T) K_k^T,$$

那么此时便令 $P^- = E(e_k^- e_k^{-T})$ ，先验误差的协方差矩阵，

$$\text{故 } P = (I - K_k H) P^- (I - K_k H)^T + K_k E(v_k v_k^T) K_k^T = (P^- - K_k H P^-) (I - H^T K_k^T) + K_k R K_k^T = P^- - K_k H P^- - P^- H^T K_k^T + K_k H P^- H^T K_k^T + K_k R K_k^T$$

求 $\text{tr}(P)$ ，此时我们发现 $K_k H P^-$ 的转置就是 $P^- H^T K_k^T$ ，如果一个矩阵是另一个矩阵的转置的话，那么两个矩阵的迹 tr 是一样的，故

$$\text{tr}(P) = \text{tr}(P^-) - 2\text{tr}(K_k H P^-) + \text{tr}(K_k H P^- H^T K_k^T) + \text{tr}(K_k R K_k^T),$$

此时求得最小值，那么便是对 K_k 求导，

$$\frac{d(\text{tr}(P))}{d(K_k)} = 0,$$

因为第一项没有 K_k ，故为 0，第二项根据雅可比矩阵

$$\text{假设有两个矩阵 } A, B, \text{ 那么 } A = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}, B = \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{bmatrix},$$

那么相乘可得到下面的形式：

$$\begin{bmatrix} a_{11}b_{11} + a_{12}b_{21} & a_{11}b_{12} + a_{12}b_{22} \\ a_{21}b_{11} + a_{22}b_{21} & a_{21}b_{12} + a_{22}b_{22} \end{bmatrix},$$

$$\text{那么 } \text{tr}(AB) = a_{11}b_{11} + a_{12}b_{21} + a_{21}b_{12} + a_{22}b_{22},$$

根据雅可比矩阵

$$\frac{d(\text{tr}(AB))}{d(A)} = \begin{bmatrix} \frac{d(\text{tr}(AB))}{d(a_{11})} & \frac{d(\text{tr}(AB))}{d(a_{12})} \\ \frac{d(\text{tr}(AB))}{d(a_{21})} & \frac{d(\text{tr}(AB))}{d(a_{22})} \end{bmatrix} = \begin{bmatrix} b_{11} & b_{21} \\ b_{12} & b_{22} \end{bmatrix} = B^T$$

所以第二项求导后为 $-2(HP^-)^T$ ，同理第三项是 ABA^T 的形式，按照上面的推导，可以得到结果为 $2AB$ ，

那么第三项求导后为 $2K_k H P^- H^T$ ，同理可以得到第四项。

$$\text{因此 } \frac{d(\text{tr}(P))}{d(K_k)} = 0 - 2(HP^-)^T + 2K_k H P^- H^T + 2K_k R = 0, \text{ 而协方差矩阵 } P^- \text{ 的转置有等于他本身}$$

$$\text{故可以得到 } -P^- H^T + K_k H P^- H^T + K_k R = 0 \rightarrow K_k (H P^- H^T + R) = P^- H^T$$

故 $K_k = P^- H^T (H P^- H^T + R)^{-1}$ ，为方便理解，我这里先写成分子分母的形式，但实际矩阵不应该这么写，

$$K_k = \frac{P^- H^T}{H P^- H^T + R},$$

可以看到当 R 特别大的时候，也就是测量的误差特别大的时候， $K_k \rightarrow 0$ ，而由上面我们可以得知，当 $K_k \rightarrow 0$ 时， $\hat{X}_k \rightarrow \hat{X}_k^-$ ，确实是满足噪声特别大的时候而当 R 比较大的时候， $K_k \rightarrow H^{-1}$ ，而由上面我们可以得知，当 $K_k \rightarrow H^{-1}$ 时， $\hat{X}_k \rightarrow \hat{X}_{k_{mea}}$ ，确实是满足噪声特别小的时候，要听从测量值的结论。

Part4 误差协方差矩阵

2023年3月30日 21:37

这是之前所推出来的内容

$$\begin{aligned}X_k &= AX_{k-1} + BU_{k-1} + \omega_{k-1} & \omega &\sim \mathcal{P}(0, Q) \\Z_k &= HX_k + v_k & v &\sim \mathcal{P}(0, R)\end{aligned}$$

先验估计

$$\hat{X}_k^- = A\hat{X}_{k-1} + BU_{k-1}$$

后验估计

$$\hat{X}_k = \hat{X}_k^- + K_k(Z_k - H\hat{X}_k^-)$$

卡尔曼增益

$$K_k = \frac{P_k^- H^T}{H P_k^- H^T + R}$$

而目前，我们虽然求得了 K_k 的公式，但是 P^- 也就是图中 P^-_k 目前还是未知的，所以我们需要求的先验误差的协方差矩阵。

$P^- = E(e_k^- e_k^{-T})$, $e_k^- = X_k - \hat{X}_k^-$ (就是真实值减去先验估计值)

真实值 $X_k = AX_{k-1} + BU_{k-1} + \omega_{k-1}$

先验估计值 $\hat{X}_k^- = A\hat{X}_{k-1} + BU_{k-1}$

那么便可以得到 $e_k^- = AX_{k-1} + BU_{k-1} + \omega_{k-1} - (A\hat{X}_{k-1} + BU_{k-1}) = AX_{k-1} + \omega_{k-1} - A\hat{X}_{k-1} = A(X_{k-1} - \hat{X}_{k-1}) + \omega_{k-1}$

而 $X_{k-1} - \hat{X}_{k-1} = e_{k-1}$

故 $e_k^- = Ae_{k-1} + \omega_{k-1}$,

所以 $P^- = E(e_k^- e_k^{-T}) = E((Ae_{k-1} + \omega_{k-1})(Ae_{k-1} + \omega_{k-1})^T) = E((Ae_{k-1} + \omega_{k-1})(e_{k-1}^T A^T + \omega_{k-1}^T)) = E(Ae_{k-1}e_{k-1}^T A^T + Ae_{k-1}\omega_{k-1}^T + \omega_{k-1}e_{k-1}^T A^T + \omega_{k-1}\omega_{k-1}^T)$

$P^- = E(Ae_{k-1}e_{k-1}^T A^T) + E(Ae_{k-1}\omega_{k-1}^T) + E(\omega_{k-1}e_{k-1}^T A^T) + E(\omega_{k-1}\omega_{k-1}^T)$,

而由于 ω_{k-1} 作用在 X_k 上, 跟 $e_{k-1} = X_{k-1} - \hat{X}_{k-1}$, 并没有关系, 故两个是独立的, 又都是高斯分布, 所以中间那两个便是0, 所以

$P^- = E(Ae_{k-1}e_{k-1}^T A^T) + E(\omega_{k-1}\omega_{k-1}^T) = AE(e_{k-1}e_{k-1}^T)A^T + E(\omega_{k-1}\omega_{k-1}^T)$,

而 $E(e_{k-1}e_{k-1}^T) = P_{k-1}^-$, $E(\omega_{k-1}\omega_{k-1}^T) = Q$

所以 $P^-_k = AP_{k-1}^- A^T + Q$

有了这些式子之后, 就可以用kalman filter 去估计状态变量的值了。

有两步, 首先是预测, 然后是校正, 在预测中也有两步

预测中:

先求先验估计值 $\hat{X}_k^- = A\hat{X}_{k-1} + BU_{k-1}$

然后求先验误差协方差矩阵: $P^-_k = AP_{k-1}^- A^T + Q$

先求先验估计值 $\hat{X}_k^- = A\hat{X}_{k-1} + BU_{k-1}$

先验误差协方差矩阵: $P^-_k = AP_{k-1}^- A^T + Q$

Kalman gain: $K_k = P^- H^T (HP^- H^T + R)^{-1}$

后验估计: $\hat{X}_k = \hat{X}_k^- + K_k(Z_k - H\hat{X}_k^-)$

更新先验误差协方差矩阵 $P = (I - K_k H)P^-$

在校正中:

首先计算kalman gain: $K_k = P^- H^T (HP^- H^T + R)^{-1}$

然后再求后验估计: $\hat{X}_k = \hat{X}_k^- + K_k(Z_k - H\hat{X}_k^-)$

在这里我们(求先验误差协方差矩阵)的时候会用到上一次的先验误差协方差矩阵

因此在用完之后还需要再更新先验误差协方差矩阵

在上一部分中我们计算得到的

$P = P^- - K_k H P^- - P^- H^T K_k^T + K_k H P^- H^T K_k^T + K_k R K_k^T = P^- - K_k H P^- - P^- H^T K_k^T +$

$K_k (H P^- H^T + R) K_k^T$,

代入 $K_k = P^- H^T (H P^- H^T + R)^{-1}$,

$P = P^- - K_k H P^- - P^- H^T K_k^T + P^- H^T K_k^T = P^- - K_k H P^- = (I - K_k H)P^-$

这就是完整的kalman filter 的五个公式了

Part5 Kalman Filter 的具体应用

2023年3月30日 23:17

2D例子



一个人在走路，状态可以由两个变量进行表示， x_1 表示人的位置， x_2 表示人的速度，假设人在匀速直线行驶(也就是 $x_{2k} = x_{2k-1}$)，采样时刻 ΔT 为K时刻和K-1时刻的时间差

位置： $x_{1,k} = x_{1,k-1} + \Delta T x_{2,k-1}$ ，令 $\Delta T = 1$

接下来，我们就要考虑过程中的噪声了。

$$x_{1,k} = x_{1,k-1} + \Delta T x_{2,k-1} + \omega_{1,k-1}$$

速度也要考虑噪声：

$$x_{2,k} = x_{2,k-1} + \omega_{2,k-1}$$

加上天上的卫星进行实时的观测。

$$Z_{1,k} = x_{1,k} + v_{1,k}$$

$$Z_{2,k} = x_{2,k} + v_{2,k}$$

写成矩阵的形式：

$$\begin{bmatrix} x_{1,k} \\ x_{2,k} \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_{1,k-1} \\ x_{2,k-1} \end{bmatrix} + \begin{bmatrix} \omega_{1,k-1} \\ \omega_{2,k-1} \end{bmatrix}$$

$$\begin{bmatrix} z_{1,k} \\ z_{2,k} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_{1,k} \\ x_{2,k} \end{bmatrix} + \begin{bmatrix} v_{1,k} \\ v_{2,k} \end{bmatrix}$$

Extend Kalman filter(EKF)

2023年3月31日 17:10

线性系统的状态方程：

$$\begin{aligned}x_k &= Ax_{k-1} + Bu_{k-1} + \omega_{k-1} \\z_k &= Hx_{k-1} + v_k \\P(\omega) &\sim (0, Q), \\P(v) &\sim (0, R)\end{aligned}$$

有了这些式子之后，就可以用kalman filter 去估计状态变量的值了。
有两步，首先是预测，然后是校正，在预测中也有两步

预测中：

先求先验估计值 $\hat{x}_k^- = A\hat{x}_{k-1} + Bu_{k-1}$
然后求先验误差协方差矩阵： $P_k^- = AP_{k-1}A^T + Q$

在校正中：

首先计算kalman gain： $K_k = P^-H^T(HP^-H^T + R)^{-1}$
然后再求后验估计： $\hat{x}_k = \hat{x}_k^- + K_k(Z_k - H\hat{x}_k^-)$

在这里我们(求先验误差协方差矩阵)的时候会用到上一次的先验误差协方差矩阵

因此在用完之后还需要再更新先验误差协方差矩阵

在上一部分中我们计算得到的
$$P = P^- - K_kHP^- - P^-H^TK_k^T + K_kRPK_k^T = P^- - K_kHP^- - P^-H^TK_k^T + K_k(HP^-H^T + R)K_k^T,$$

代入 $K_k = P^-H^T(HP^-H^T + R)^{-1}$,
$$P = P^- - K_kHP^- - P^-H^TK_k^T + P^-H^TK_k^T = P^- - K_kHP^- = (I - K_kH)P^-$$

这就是完整的kalman filter 的五个公式了


而对于一个非线性(Nonlinear)的系统来说

只能写成下面的这种形式：
$$\begin{aligned}x_k &= f(x_{k-1}, u_{k-1}, \omega_{k-1}) \\z_k &= h(x_k, v_k) \\P(\omega) &\sim (0, Q), \\P(v) &\sim (0, R)\end{aligned}$$

正态分布的随机变量通过非线性系统之后就不再是正态的了


这其实很好懂：

假如是一个线性系统的话，那么我们可以由下面的图可以看到



正态分布经过映射之后还是正态分布。

那如果是非线性系统的话，那么显然他将不会是处于正态分布的情况了



所以说如果还是想要对这个系统进行卡尔曼滤波的话，就要对这个系统进行线性化 (linearization)

在这里会用到泰勒级数展开。

$$f(x) = f(x_0) + \frac{\partial f(x)}{\partial x} (x - x_0) + \frac{\partial^2 f(x)}{2! \partial x^2} (x - x_0)^2 + \dots + \Delta(o)$$

就是在非线性函数的具体某一点上进行泰勒级数展开，把他变成一个线性的系统，然后把一个完成的非线性函数离散成无数条离散的线性函数。

但是系统是存在误差的，我们永远不知道函数中的真实点是多少，因此也就无法在该点进行泰勒级数展开。

因此退而求其次，我们将 $f(x_k)$ 在 \hat{x}_{k-1} 处进行线性化。也就是上一时刻的后验估计。

因此在上面的公式可以写为：

$$\begin{aligned}x_k &= f(x_{k-1}, u_{k-1}, \omega_{k-1}) = f(\hat{x}_{k-1}, u_{k-1}, \omega_{k-1}) + A_k(x_k - \hat{x}_{k-1}) + B_k \omega_{k-1} \\A_k &= \frac{\partial f}{\partial x} |_{\hat{x}_{k-1}, u_{k-1}, \omega_{k-1}} \\B_k &= \frac{\partial f}{\partial \omega} |_{\hat{x}_{k-1}, u_{k-1}, \omega_{k-1}}\end{aligned}$$

因为我们还不了解 ω_{k-1} 的具体情况，因此为了简化，我们将其忽略掉

$$x_k = f(x_{k-1}, u_{k-1}, \omega_{k-1}) = f(\hat{x}_{k-1}, u_{k-1}, \omega_{k-1}) + A_k(x_k - \hat{x}_{k-1}) + B_k \omega_{k-1}$$

A是雅可比矩阵

$$A_k = \frac{\partial f}{\partial x} |_{\hat{x}_{k-1}, u_{k-1}}$$

$$B_k = \frac{\partial f}{\partial \omega} |_{\hat{x}_{k-1}, u_{k-1}}$$

下面举一个例子

$$\begin{aligned}x_1 &= x_1 + s_1 u_1 \\x_2 &= x_1^2 = f_2 \\A &= \frac{\partial f}{\partial x} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} \end{bmatrix} \\&= \begin{bmatrix} 1 & \cos x_2 \\ 2x_1 & 0 \end{bmatrix} \begin{bmatrix} x_{1,k-1} \\ x_{2,k-1} \end{bmatrix} \\&= \begin{bmatrix} 1 & \cos x_{2,k-1} \\ 2x_{1,k-1} & 0 \end{bmatrix}\end{aligned}$$

考虑高斯白噪声的非线性系统：

$$\begin{cases}x_{k+1} = f(x_k) + w_k \\z_k = h(x_k) + v_k\end{cases}$$

x_k 为状态向量， z_k 量测向量， $f(\cdot)$ 和 $h(\cdot)$ 分别为系统非线性状态函数和量测函数
 w_k 和 v_k 分别是零均值，协方差为 Q_k 和 R_k 的不相关高斯白噪声。

假设我们已知 k 时刻状态估计值 $\hat{x}_{k|k}$ 和估计方差 $P_{k|k}$ ，

我们将非线性函数 $f(x_k)$ 在 $\hat{x}_{k|k}$ 处进行一阶泰勒展开可得：

$$f(x_k) = f(\hat{x}_{k|k}) + \frac{\partial f}{\partial x} |_{x_k = \hat{x}_{k|k}} (x_k - \hat{x}_{k|k}) + o(x_k - \hat{x}_{k|k})$$

其中 $o(x_k - \hat{x}_{k|k})$ 为高阶项，我们定义 $\frac{\partial f}{\partial x} |_{x_k = \hat{x}_{k|k}} = F_k$ ，忽略高阶项，状态方程 可以化简为：

$$x_{k+1} = f(\hat{x}_{k|k}) + F_k(x_k - \hat{x}_{k|k}) + w_k$$

一步状态预测： $\hat{x}_{k+1|k} = E[f(\hat{x}_{k|k}) + F_k(x_k - \hat{x}_{k|k}) + w_k] = f(\hat{x}_{k|k})$

一步预测协方差：
$$\begin{aligned}P_{k+1|k} &= E[(x_{k+1} - \hat{x}_{k+1|k})(x_{k+1} - \hat{x}_{k+1|k})^T] \\&= E\{[F_k(x_k - \hat{x}_{k|k}) + w_k][F_k(x_k - \hat{x}_{k|k}) + w_k]^T\} \\&= F_k P_{k|k} F_k^T + Q_k\end{aligned}$$

将非线性函数 $h(\cdot)$ 在一步状态预测 $\hat{x}_{k+1|k}$ 处一阶泰勒展开得：

$$h(x_{k+1}) = h(\hat{x}_{k+1|k}) + \frac{\partial h}{\partial x} |_{x_{k+1} = \hat{x}_{k+1|k}} (x_{k+1} - \hat{x}_{k+1|k}) + o(x_{k+1} - \hat{x}_{k+1|k})$$

其中 $o(x_{k+1} - \hat{x}_{k+1|k})$ 为高阶项，我们令 $\frac{\partial h}{\partial x} |_{x_{k+1} = \hat{x}_{k+1|k}} = H_{k+1}$ ，所以量测方程可表示为：

$$z_{k+1} = h(\hat{x}_{k+1|k}) + H_{k+1}(x_{k+1} - \hat{x}_{k+1|k}) + v_{k+1}$$

所以量测一步预测： $\hat{z}_{k+1} = E[h(\hat{x}_{k+1|k}) + H_{k+1}(x_{k+1} - \hat{x}_{k+1|k}) + v_{k+1}] = h(\hat{x}_{k+1|k})$

量测预测误差协方差阵：
$$\begin{aligned}P_{z_{k+1|k}} &= E[(z_{k+1} - \hat{z}_{k+1})(z_{k+1} - \hat{z}_{k+1})^T] \\&= E\{[H_{k+1}(x_{k+1} - \hat{x}_{k+1|k}) + v_{k+1}][H_{k+1}(x_{k+1} - \hat{x}_{k+1|k}) + v_{k+1}]^T\} \\&= H_{k+1} P_{k+1|k} H_{k+1}^T + R_{k+1}\end{aligned}$$

状态与量测间的互协方差矩阵：
$$\begin{aligned}P_{x_{k+1}z_{k+1|k}} &= E[(x_{k+1} - \hat{x}_{k+1|k})(z_{k+1} - \hat{z}_{k+1})^T] \\&= E\{(x_{k+1} - \hat{x}_{k+1|k})[H_{k+1}(x_{k+1} - \hat{x}_{k+1|k}) + v_{k+1}]^T\} \\&= P_{k+1|k} H_{k+1}^T\end{aligned}$$

状态增益矩阵。

$$-A_{k+1|k}A_{k+1}$$

1. 2. 3. 4. 5. 6. 7. 8. 9. 10. 11. 12. 13. 14. 15. 16. 17. 18. 19. 20. 21. 22. 23. 24. 25. 26. 27. 28. 29. 30. 31. 32. 33. 34. 35. 36. 37. 38. 39. 40. 41. 42. 43. 44. 45. 46. 47. 48. 49. 50. 51. 52. 53. 54. 55. 56. 57. 58. 59. 60. 61. 62. 63. 64. 65. 66. 67. 68. 69. 70. 71. 72. 73. 74. 75. 76. 77. 78. 79. 80. 81. 82. 83. 84. 85. 86. 87. 88. 89. 90. 91. 92. 93. 94. 95. 96. 97. 98. 99. 100.

状态增益矩阵:

$$K_{k+1} = P_{x_{k+1}|k} (P_{z_{k+1}|k}^{-1})^{-1} = P_{k+1|k} H_{k+1}^T (H_{k+1} P_{k+1|k} H_{k+1}^T + R_{k+1})^{-1}$$

$$k+1 \text{时刻状态估计值: } \hat{x}_{k+1|k+1} = \hat{x}_{k+1|k} + K_{k+1}(z_{k+1} - \hat{z}_{k+1|k})$$

状态估计误差协方差矩阵:

$$\begin{aligned} P_{k+1|k+1} &= E[(x_{k+1} - \hat{x}_{k+1|k+1})(x_{k+1} - \hat{x}_{k+1|k+1})^T] \\ &= E\{[x_{k+1} - \hat{x}_{k+1|k} - K_{k+1}(z_{k+1} - \hat{z}_{k+1|k})][x_{k+1} - \hat{x}_{k+1|k} - K_{k+1}(z_{k+1} - \hat{z}_{k+1|k})]^T\} \\ &= (I - K_{k+1}H_{k+1})P_{k+1|k}(I - K_{k+1}H_{k+1})^T + K_{k+1}R_{k+1}K_{k+1}^T \\ &= (I - K_{k+1}H_{k+1})P_{k+1|k} \end{aligned}$$

$$\begin{bmatrix} 2x_1 & 0 \\ 0 & 2x_2 \end{bmatrix} = \begin{bmatrix} 1 & \omega_3 \hat{x}_{k-1} \\ 2\hat{x}_{k-1} & 0 \end{bmatrix}$$

可以看到 A_k 在随着 k 的变化而不断地变化

我们将 $f(\hat{x}_{k-1}, u_{k-1}, 0)$ 定义为 \hat{x}_k^-

对于测量方程而言: 那么就让 z_k 在 \hat{x}_k 附近进行线性化。

$$z_k = h(x_k, v_k) = h(\hat{x}_k, v_k) + H_k(x_k - \hat{x}_k) + C_k v_k$$

同样是假设 $v_k = 0$

$$H_k = \frac{\partial f}{\partial x} | \hat{x}_k,$$

$$C_k = \frac{\partial f}{\partial v} | \hat{x}_k,$$

我们将 $h(\hat{x}_k, 0)$ 定义为 \hat{z}_k

那么式子便可以改写为:

$$x_k = f(x_{k-1}, u_{k-1}, \omega_{k-1}) = \hat{x}_k + A_k(x_k - \hat{x}_{k-1}) + B_k \omega_{k-1}$$

$$z_k = h(x_k, v_k) = \hat{z}_k + H_k(x_k - \hat{x}_k) + C_k v_k$$

而 $B_k \omega_{k-1}$ 和 $C_k v_k$ 仍然是满足正态分布的, 不过变成了 $(0, B_k Q B_k^T)$ 和 $(0, C_k R C_k^T)$ 左乘加上右乘转置, 这样得到的结果就类似于平方

那么那五个式子便可以写成

$$\text{先验: } \hat{x}_k^- = f(\hat{x}_{k-1}, u_{k-1}, 0)$$

$$\text{先验误差的协方差矩阵为: } P_{k-} = A P_{k-1} A^T + B_k Q B_k^T$$

$$\text{Kalman filter的增益改为: } K_k = P_{k-} H^T (H P_{k-} H^T + C_k R C_k^T)^{-1}$$

$$\text{那么再求后验估计: } \hat{x}_k = \hat{x}_k^- + K_k (z_k - h(\hat{x}_k, 0))$$

$$P = P_{k-} - K_k H P_{k-} = P_{k-} H^T K_k^T + P_{k-} H^T K_k^T = P_{k-} - K_k H P_{k-} = (I - K_k H) P_{k-} \text{ 不变}$$